

5. Übungsblatt

Ksenia Klassen
ksenia.klassen@udo.edu

Dag-Björn Hering
dag.hering@udo.edu

Henning Ptaszyk
henning.ptaszyk@udo.edu

6. Dezember 2016

1 Aufgabe 1

1.1 a)

Zunächst wird für beide Populationen der Mittelwert berechnet.

$$\mu_{P0} \approx \begin{pmatrix} 0,022 \\ 3,026 \end{pmatrix} \quad (1)$$

$$\mu_{P1} \approx \begin{pmatrix} 5,986 \\ 3,026 \end{pmatrix} \quad (2)$$

1.2 b)

Die Kovarianzmatrix S_{P0} und S_{P1} berechnen sich über

$$S_j = \sum_i^{n_j} (\vec{x} - \vec{\mu}_j)(\vec{x} - \vec{\mu}_j)^T \quad (3)$$

zu

$$S_{P0} \approx \begin{pmatrix} 122904 & 81979 \\ 81979 & 67449 \end{pmatrix} \quad (4)$$

und

$$S_{P1} \approx \begin{pmatrix} 122344 & 73118 \\ 73118 & 53845 \end{pmatrix} \quad (5)$$

Aus $S_{P0P1} = S_{P0} + S_{P1}$ folgt

$$S_{P0P1} \approx \begin{pmatrix} 245248 & 155097 \\ 155097 & 121294 \end{pmatrix} \quad (6)$$

Desweiteren muss noch S_B über

$$S_B = (\vec{\mu}_1 - \vec{\mu}_2)(\vec{\mu}_1 - \vec{\mu}_2)^T \quad (7)$$

berechnet werden.

$$\Rightarrow S_B \approx \begin{pmatrix} 35.562 & 0.432 \\ 0.432 & 0.005 \end{pmatrix} \quad (8)$$

1.3 c)

Um nun die Fisher-Diskriminate zu berechnen, müssen die Eigenwerte und Eigenvektoren der Matrix

$$A = S_{P0P1}^{-1} S_B \quad (9)$$

berechnet werden. Die Inverse von $S_{P_0P_1}$ lautet:

$$S_{P_0P_1}^{-1} \approx \begin{pmatrix} 0.000021 & -0.000027 \\ -0.000027 & 0.000043 \end{pmatrix} \quad (10)$$

somit folgt für A

$$A \approx \begin{pmatrix} 0.000746 & 0.000009 \\ -0.000950 & -0.000012 \end{pmatrix} \quad (11)$$

Die Eigenwerte der Matrix A sind:

$$\lambda_1 \approx 0,0007 \quad \lambda_2 \approx 0 \quad (12)$$

Die normierten Eigenvektoren sind:

$$\vec{v}_{\lambda_1} \approx \begin{pmatrix} 0,617 \\ -0,012 \end{pmatrix} \quad (13)$$

$$\vec{v}_{\lambda_2} \approx \begin{pmatrix} -0,787 \\ 1 \end{pmatrix} \quad (14)$$

Als Projektionsvektors wird der Eigenvektor zum Eigenwert λ_1 gewählt. Daraus folgt die Geradengleichung:

$$\vec{\lambda} = \lambda \cdot \begin{pmatrix} 0,617 \\ -0,012 \end{pmatrix} \quad (15)$$

1.4 d)

Nun kann mit Hilfe des Projektionsvektors $-v_{\lambda_1}$ ein eindimensionales Histogramm der Populationen 1 berechnet werden. Das Minus dreht die Orientierung so, dass P_0 rechts von P_1 liegt.




Abbildung 1: Histogramm der Projektion von den Populationen $P0$ und $P1$ auf die Projektionsgeraden $\tilde{\lambda}$.

1.5 e)

Betrachtet man nun $P0$ als Signal und $P1$ als Untergrund kann die Effizienz und Reinheit des Signals als Funktion eines Schnitts λ_{cut} aufgetragen werden. Die folgende Abbildung 2 enthält die Effizienz und Reinheit in Abhängigkeit von λ_{cut} .




Abbildung 2: Effizienz und Reinheit des Schnittes ausgehend von der Gerade $\bar{\lambda}$ in Abhängigkeit von λ_{cut} .

1.6 f)

In der Abbildung 3 ist das Signal-zu-Untergrundverhältnis(t_p/f_p) in Abhängigkeit von dem Schnittes λ_{cut} aufgetragen.

Bei

$$\lambda_{cut} \approx 2,2 \quad (16)$$

wird das Signal-zu-Untergrundverhältnis maximal.

1.7 g)

Ebenfalls kann die Signifikanz $t_p/\sqrt{t_p + f_p}$ in Abhängigkeit von dem Schnittes λ_{cut} aufgetragen werden 4. Diese besitzt bei

$$\lambda_{cut} \approx 0.58 \quad (17)$$

ein Maximum.




Abbildung 3: Das Signal-zu-Untergrundverhältnis in Abhängigkeit von λ_{cut} .




Abbildung 4: Die Signifikanz in Abhängigkeit von λ_{cut} .

1.8 h)

Die Schritte *e)* bis *g)* werden nun für den Fall, dass $P0$ nun die Population P_0_1000 bezeichnet wiederholt. Es ergibt sich die Projektion 5.




Abbildung 5: Histogramm der Projektion von den Populationen $P0$ und $P1$ auf die Projektionsgeraden $\hat{\lambda}$.

Wieder kann die Effizienz und Reinheit berechnet werden 6, so wie das Signal-zu-Untergrundverhältnis 7, dass bei

$$\lambda_{cut} \approx 2,2 \quad (18)$$

ein Maximum besitzt. Die Signifikanz, die in der Abbildung 8 dargestellt ist, wird bei

$$\lambda_{cut} \approx 1,1 \quad (19)$$

maximal.




Abbildung 6: Effizienz und Reinheit des Schnittes ausgehend von der Geraden $\vec{\lambda}$ in Abhängigkeit von λ_{cut} .

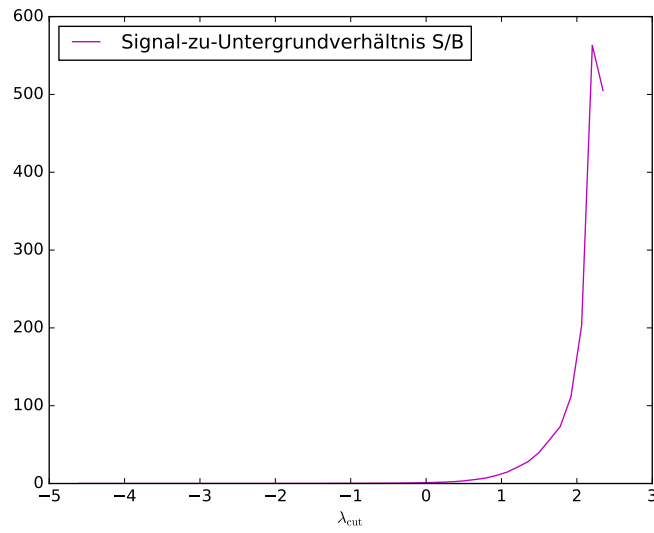


Abbildung 7: Das Signal-zu-Untergrundverhältnis in Abhängigkeit von λ_{cut} .




Abbildung 8: Die Signifikanz in Abhängigkeit von λ_{cut} .

2 Aufgabe2




Abbildung 1: Population zum Einzeichnen der Clusterzentren und Clustergrenzen.
 Zu Aufgabe 2

a) Bestimmung des Zentrums mittels Mittelwertbildung:

Schritt 1: Zentrum 1: Zentrum 2: Zentrum 3:

Bsp: $x = \frac{1+1+3+4+5}{5} = \frac{17}{5}$

$z_1: \left(\frac{41}{6}; \frac{7}{2}\right)$

$z_3: (1; 6)$

$y = \frac{8}{3} \Rightarrow z_1: \left(\frac{17}{5}; \frac{8}{3}\right)$

Schritt 2:

$z_1: \left(\frac{15}{4}; \frac{7}{4}\right)$

$z_2: \left(\frac{36}{5}; 4\right)$

$z_3: (1; 5)$

Schritt 3:

$z_1: \left(\frac{21}{5}; \frac{9}{5}\right)$

$z_2: \left(\frac{15}{2}; \frac{9}{2}\right)$

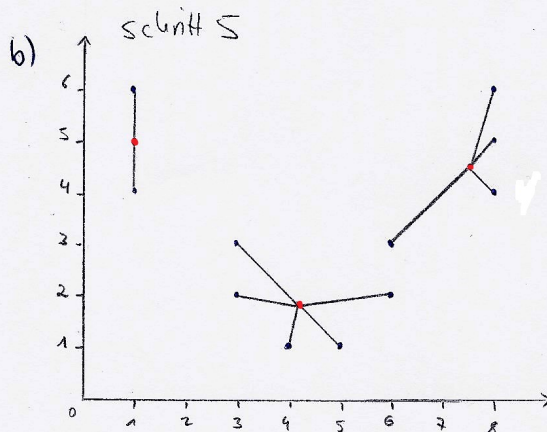
$z_3: (1; 5)$

Schritt 4:

$z_1: \left(\frac{21}{5}; \frac{9}{5}\right)$

$z_2: \left(\frac{15}{2}; \frac{9}{2}\right)$

$z_3: (1; 5)$



Nach vier weiteren Iterationsschritten, bekommt man das gleiche Bild. Die Zentren liegen im gleichen Punkt.

c) Das Verfahren konvergiert nach drei Schritten.

Abbildung 10

3 Aufgabe3

Siehe beigelegte Ordner.